

作业

(1) 用矩阵符号推演证明 $B=S^{-1}AS$

$$\begin{aligned} \mathbf{V} &= \mathbf{U}S, L(\mathbf{U}) = \mathbf{U}A, L(\mathbf{V}) = \mathbf{V}B \\ \Rightarrow \mathbf{V}B &= L(\mathbf{V}) = L(\mathbf{U}S) = L(\mathbf{U})S = \mathbf{U}AS \\ \Rightarrow \mathbf{U}SB &= \mathbf{U}AS \\ \Rightarrow SB &= AS \\ \Rightarrow B &= S^{-1}AS \end{aligned}$$

注:

1) 黑体字母表示基向量从左到右排列的一个代数表示, 此处不能理解成一个矩阵。

2) 矢量、线性变换是线性空间里的研究对象, 它们的存在不依赖于基的存在。

线性空间: R^n (维数为 n), R^m (维数为 m)

矢量 (向量): $X \in R^n, Y \in R^m, n$ 和 m 都是大于零的整数

$$\text{线性变换: } \begin{cases} L: R^n \rightarrow R^m, \\ L(\alpha_1 X_1 + \alpha_2 X_2) = \alpha_1 L(X_1) + \alpha_2 L(X_2), \\ X_1, X_2 \in R^n, \alpha_1, \alpha_2 \in R (\text{注: 复数域类同}) \end{cases}$$

3) 但是, 要研究它们, 就必须给线性空间建立坐标系, 也就是选取一组最大线性无关组做为基。继而, 所有矢量都可以用这组基向量线性表示, 该表示的系数按基向量的排列顺序排列, 就得到了该矢量的代数表示: 向量。线性变换也如此, 用它们对基向量进行变换, 变换后的系数按矩阵方式排列, 就得到了它的代数表示: 矩阵。当有了代数表示后, 矢量和线性变换之间的数量关系及运算, 就全部落实到它们的代数表示上了, 此时, 矢量和线性变换这种抽象的东西, 就具体化了。只有基向量选定后, 矢量和线性变换的表示才能落实下来。一般我们忽略了基的问题, 是因为默认选择的基是[标准正交基](#)(此处特指: 空间里的坐标轴方向上的单位向量们)。

- 空间上的基向量是选取的, 不唯一
- 矢量在不同基下的表示也是不一样的
- 同一矢量在不同基下的代数表示可以互相转换 (计算) 得到, 称为坐标变换
- 对于线性变换, 以上说法也正确

设 $\mathbf{U} = (\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n), \tilde{\mathbf{U}} = (\tilde{\mathbf{u}}_1, \tilde{\mathbf{u}}_2, \dots, \tilde{\mathbf{u}}_n)$ 是选定的两组 R^n 上的基

$\mathbf{V} = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m), \tilde{\mathbf{V}} = (\tilde{\mathbf{v}}_1, \tilde{\mathbf{v}}_2, \dots, \tilde{\mathbf{v}}_m)$ 是选定的两组 R^m 上的基

则矢量 \mathbf{X} 和 \mathbf{Y} 在 R^n 和 R^m 上有如下表示 (用黑体表示矢量或基向量, 正体表示向量或矩阵)

$$\begin{aligned} \mathbf{X} &= x_1 \mathbf{u}_1 + x_2 \mathbf{u}_2 + \dots + x_n \mathbf{u}_n = \sum_{i=1}^n x_i \mathbf{u}_i = (\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n) \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \mathbf{U}X \\ \mathbf{X} &= \tilde{x}_1 \tilde{\mathbf{u}}_1 + \tilde{x}_2 \tilde{\mathbf{u}}_2 + \dots + \tilde{x}_n \tilde{\mathbf{u}}_n = \sum_{i=1}^n \tilde{x}_i \tilde{\mathbf{u}}_i = (\tilde{\mathbf{u}}_1, \tilde{\mathbf{u}}_2, \dots, \tilde{\mathbf{u}}_n) \begin{pmatrix} \tilde{x}_1 \\ \tilde{x}_2 \\ \vdots \\ \tilde{x}_n \end{pmatrix} = \tilde{\mathbf{U}}\tilde{X} \end{aligned}$$

$$\mathbf{Y} = y_1 \mathbf{v}_1 + y_2 \mathbf{v}_2 + \cdots + y_m \mathbf{v}_m = \sum_{i=1}^m x_i \mathbf{v}_i = (\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_m) \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix} = \mathbf{V} \mathbf{Y}$$

$$\mathbf{Y} = \tilde{y}_1 \tilde{\mathbf{v}}_1 + \tilde{y}_2 \tilde{\mathbf{v}}_2 + \cdots + \tilde{y}_m \tilde{\mathbf{v}}_m = \sum_{i=1}^m \tilde{y}_i \tilde{\mathbf{v}}_i = (\tilde{\mathbf{v}}_1, \tilde{\mathbf{v}}_2, \cdots, \tilde{\mathbf{v}}_m) \begin{pmatrix} \tilde{y}_1 \\ \tilde{y}_2 \\ \vdots \\ \tilde{y}_m \end{pmatrix} = \tilde{\mathbf{V}} \tilde{\mathbf{Y}}$$

注：左边是繁写，右边是简写，是数学记号的问题。数学记号的使用，是为了方便。
大家不要纠缠矢量和向量的学术意义上的区别，不同人与不同人的看法不一样。为方便起见，为了概念的细微辨识，本文所说矢量，是指一种物理量。向量是矢量的一种数学表示形式。明白这个区别就行。
对于线性变换，必有

$$L(\mathbf{u}_i) = a_{i1} \mathbf{v}_1 + a_{i2} \mathbf{v}_2 + \cdots + a_{im} \mathbf{v}_m = (\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_m) (a_{i1}, a_{i2}, \cdots, a_{im})^T, i=1, 2, \cdots, n$$

也就是

$$L((\mathbf{u}_1, \mathbf{u}_2, \cdots, \mathbf{u}_n)) = (\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_m) \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \cdots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix}$$

简记为

$L(\mathbf{U}) = \mathbf{V} \mathbf{A}$ （注：此处的 \mathbf{A} 与本题解答的红色部分里的 \mathbf{A} 没有关系，此处只是这里使用的一个记号，其含义不解释了，自明。写此公式的时候，没有看红色部分里的那个公式，已经写好了，不想再换其他符号了）

这个 \mathbf{A} 称为线性变换在基 \mathbf{U} 和 \mathbf{V} 下的表示矩阵。如果自变量空间和应变量空间各选两组基，则一共有四种表示矩阵 $(\mathbf{A}, \mathbf{A}_1, \mathbf{A}_2, \mathbf{A}_3)$ 。

$$L(\mathbf{U}) = \mathbf{V} \mathbf{A}$$

$$L(\mathbf{U}) = \tilde{\mathbf{V}} \mathbf{A}_1$$

$$L(\tilde{\mathbf{U}}) = \mathbf{V} \mathbf{A}_2$$

$$L(\tilde{\mathbf{U}}) = \tilde{\mathbf{V}} \mathbf{A}_3$$

它们都表示同一线性变换 L

如果明白了以上内容，关于基向量的事情，就没有障碍了。

(2) 用矩阵符号推演证明如下两个公式

令 \mathbf{I} 为单位矩阵，则：

$$\text{eig}(\mathbf{I} + c\mathbf{A}) = \mathbf{I} + c \cdot \text{eig}(\mathbf{A})$$

$$\text{eig}(\mathbf{A} - c\mathbf{I}) = \text{eig}(\mathbf{A}) - c$$

解：

证明：

①记 $\lambda = \text{eig}(A)$,
 $\because \exists \mathbf{x}$, 使 $A\mathbf{x} = \lambda\mathbf{x}$,
 $\therefore (cA + I)\mathbf{x} = c\lambda\mathbf{x} + \mathbf{x} = (1 + c\lambda)\mathbf{x}$,
 $\therefore 1 + c\lambda$ 是 $cA + I$ 的特征值,
 得证。

②记 $\lambda = \text{eig}(A)$,
 $\because \exists \mathbf{x}$, 使 $A\mathbf{x} = \lambda\mathbf{x}$,
 $\therefore (A - cI)\mathbf{x} = \lambda\mathbf{x} - c\mathbf{x} = (\lambda - c)\mathbf{x}$,
 $\therefore \lambda - c$ 是 $A - cI$ 的特征值,
 得证。

(3)书本习题

1.1

解：根据图得到：

$$\begin{cases} x_1 + x_5 = 800; \\ x_1 + x_4 = 400 + x_2; \\ x_3 + 600 = x_2; \\ 1600 + x_3 = 400 + x_7; \\ x_7 = x_4 + x_6; \\ x_5 + x_6 = 1000; \end{cases}$$

整理可得：

$$\begin{cases} x_1 + x_5 = 800; \\ x_1 - x_2 + x_4 = 400; \\ x_2 - x_3 = 600; \\ x_3 - x_7 = -1200; \\ x_4 + x_6 - x_7 = 0; \\ x_5 + x_6 = 1000; \end{cases}$$

有 7 个未知数，但只有 6 个式子，所以矩阵的秩 <7 ，即有无穷多个解。

写出增广矩阵：

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 800 \\ 1 & -1 & 0 & 1 & 0 & 0 & 0 & 400 \\ 0 & 1 & -1 & 0 & 0 & 0 & 0 & 600 \\ 0 & 0 & 1 & 0 & 0 & 0 & -1 & -1200 \\ 0 & 0 & 0 & 1 & 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 0 & 1000 \end{bmatrix}$$

解得：

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \\ x_7 \end{bmatrix} = \begin{bmatrix} 800 \\ 400 \\ -200 \\ 0 \\ 0 \\ 1000 \\ 1000 \end{bmatrix} + k_1 \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} + k_2 \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

网络流问题。把 x_6 和 x_7 作为控制参数，也就是令 $k_1=1000-x_6$, $k_2=x_7-1000$ ，则网络运行状态就完全确定。

1.2

解：

$$\begin{cases} 3I_2 + 5I_3 = 4; \\ 5I_1 + 3I_2 = 2; \\ I_1 + I_3 = I_2; \end{cases}$$

写出增广矩阵：

$$\begin{bmatrix} 0 & 3 & 5 & 4 \\ 5 & 3 & 0 & 2 \\ 1 & -1 & 1 & 0 \end{bmatrix}$$

解得：

$$\begin{cases} I_1 = 0.0727(A) \\ I_2 = 0.5455(A) \\ I_3 = 0.4727(A) \end{cases}$$

1.3

解：

(1): 因为 $\text{rank} \begin{bmatrix} B, AB, A^2B \end{bmatrix} = \text{rank} \begin{bmatrix} 0 & 1 & 0 \\ 1 & -0.9 & 0.81 \\ 1 & 0.5 & 0.25 \end{bmatrix} = 3$

所以矩阵对 (A, B) 是可控的。

(2): 因为 $\text{rank} \begin{bmatrix} B, AB, A^2B \end{bmatrix} = \text{rank} \begin{bmatrix} 1 & 0.5 & 0.19 \\ 1 & 0.7 & 0.45 \\ 0 & 0 & 0 \end{bmatrix} = 2$

所以矩阵对 (A, B) 是不可控的。

1.7

解：

证明如下：

$$\because x_1 \neq x_2, y_1 \neq y_2$$

$$\therefore \text{两点式方程可表示为: } \frac{y - y_1}{x - x_1} = \frac{y_2 - y_1}{x_2 - x_1}$$

$$\text{整理后可得: } (y_2 - y_1)x - (x_2 - x_1)y = y_2x_1 - x_2y_1$$

$$\therefore \text{写出上式的等效形式为: } \begin{vmatrix} 1 & x & y \\ 1 & x_1 & y_1 \\ 1 & x_2 & y_2 \end{vmatrix} = 0$$

得证。

1.8

解：

证明如下：

将三个点的坐标代入到平面方程中，可以得到：

$$\begin{cases} ax_1 + by_1 + cz_1 = -1 \\ ax_2 + by_2 + cz_2 = -1 \\ ax_3 + by_3 + cz_3 = -1 \end{cases}$$

利用 Gramer 法则，可以得到：

$$a = \frac{\begin{vmatrix} -1 & y_1 & z_1 \\ -1 & y_2 & z_2 \\ -1 & y_3 & z_3 \end{vmatrix}}{\begin{vmatrix} x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \\ x_3 & y_3 & z_3 \end{vmatrix}}, b = \frac{\begin{vmatrix} x_1 & -1 & z_1 \\ x_2 & -1 & z_2 \\ x_3 & -1 & z_3 \end{vmatrix}}{\begin{vmatrix} x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \\ x_3 & y_3 & z_3 \end{vmatrix}}, c = \frac{\begin{vmatrix} x_1 & y_1 & -1 \\ x_2 & y_2 & -1 \\ x_3 & y_3 & -1 \end{vmatrix}}{\begin{vmatrix} x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \\ x_3 & y_3 & z_3 \end{vmatrix}}$$

所以可以将平面方程表示为：

$$\begin{vmatrix} -1 & y_1 & z_1 \\ -1 & y_2 & z_2 \\ -1 & y_3 & z_3 \end{vmatrix} x + \begin{vmatrix} x_1 & -1 & z_1 \\ x_2 & -1 & z_2 \\ x_3 & -1 & z_3 \end{vmatrix} y + \begin{vmatrix} x_1 & y_1 & -1 \\ x_2 & y_2 & -1 \\ x_3 & y_3 & -1 \end{vmatrix} z = \begin{vmatrix} x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \\ x_3 & y_3 & z_3 \end{vmatrix}$$

将此式化简，为：

$$\begin{vmatrix} 1 & x & y & z \\ 1 & x_1 & y_1 & z_1 \\ 1 & x_2 & y_2 & z_2 \\ 1 & x_3 & y_3 & z_3 \end{vmatrix} = 0$$

得证。

1.10

解:

若向量两两求内积均为 0, 那么这就是一组正交向量;

$$\text{可求得: } \begin{bmatrix} 1 \\ 0 \\ 1 \\ 2 \end{bmatrix}^T \cdot \begin{bmatrix} -1 \\ 1 \\ 1 \\ 0 \end{bmatrix} = 0; \begin{bmatrix} -1 \\ 1 \\ 1 \\ 0 \end{bmatrix}^T \cdot \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix} = 0; \begin{bmatrix} 1 \\ 0 \\ 1 \\ 2 \end{bmatrix}^T \cdot \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix} = 0$$

所以这是一组正交向量。

1.11

解:

证明如下:

$uv^T u = (v^T u)u \Rightarrow (v^T u)$ 是 uv^T 的特征值, u 是对应的特征向量

$uv^T X = \lambda X \Rightarrow u(v^T X) = (v^T X)u = \lambda X \Rightarrow X = \alpha u, \lambda = (v^T u)$

则必定能找到与 u 正交的一组两两正交的单位向量 u_2, \dots, u_n

令 u_1 是 u 的单位化向量, $U = (u_1, u_2, \dots, u_n)$, 则

$U^{-1}uv^T U = \text{diag}(\lambda, 0, \dots, 0), U^{-1}(I + uv^T)U = \text{diag}(1 + \lambda, 1, \dots, 1),$

所以 $\det(I + uv^T) = 1 + \lambda.$

2.11

$$Q(X) = X^T \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{pmatrix} X$$

$$Q(AY) = Y^T A^T \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{pmatrix} AY$$

$$A^T \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{pmatrix} A = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{pmatrix}$$

这是洛伦兹矩阵的定义

显然, 两个洛伦兹矩阵的乘积还是洛伦兹矩阵。

在洛伦兹矩阵的变换下, 本题所述二次型的数学表达形式不变!!! (这是洛伦兹

变换的特点)

2.12

证:

1)

$$\because M = \lambda P + (1-\lambda)Q \rightarrow \sum_{i=1}^n m_{ij} = \lambda \sum_{i=1}^n p_{ij} + (1-\lambda) \sum_{i=1}^n q_{ij} = \lambda + (1-\lambda) = 1$$

$\therefore M = \lambda P + (1-\lambda)Q$ 是Markov矩阵

2)

$$\because \text{令 } M = PQ \rightarrow \sum_{i=1}^n m_{ij} = \sum_{i=1}^n \sum_{k=1}^n p_{ik} q_{kj} = \sum_{k=1}^n \sum_{i=1}^n p_{ik} q_{kj} = \sum_{k=1}^n q_{kj} = 1$$

$\therefore PQ$ 也为Markov矩阵

2.13

证:

$\because M$ 是Markov矩阵

$$\therefore \sum_{i=1}^n m_{ij} = 1$$

$$\therefore \sum_{i=1}^n y_i = \sum_{j=1}^n \sum_{i=1}^n m_{ij} x_j = \sum_{j=1}^n x_j$$

$\because x$ 是概率向量

$$\therefore \sum_{j=1}^n x_j = 1$$

$$\therefore \sum_{i=1}^n y_i = 1 \text{ 且 } y_i \geq 0 (i = 1, 2, \dots, n)$$

\therefore 可证 $y = Mx$ 是概率向量

3.6

```
>> A=[-2,4,3;0,0,0;-1,5,2]
```

```
A =
```

```
    -2     4     3
     0     0     0
    -1     5     2
```

```
>> [U,D]=eig(A)
```

```
U =
```

```
   -0.9487   -0.7071   -0.7548
           0           0    0.1078
   -0.3162   -0.7071   -0.6470
```

```
D =
```

```
    -1     0     0
     0     1     0
     0     0     0
```

```
>> U*D/U
```

```
ans =
```

```
   -2.0000    4.0000    3.0000
           0           0         0
   -1.0000    5.0000    2.0000
```

所以，解为：

```
>> U*(D-2*D)/U
```

```
ans =
```

```
    2.0000   -4.0000   -3.0000
           0           0         0
    1.0000   -5.0000   -2.0000
```

3.7

```
>> A=[1,1,2;-1,2,1;0,1,3]
```

```
A =
```

```
     1     1     2
    -1     2     1
     0     1     3
```

```
>> [U,D]=eig(A)
```

```
U =
```

```
    0.4082   -0.5774    0.7071
    0.8165    0.5774    0.0000
   -0.4082   -0.5774    0.7071
```

```
D =
```

```
    1.0000         0         0
         0    2.0000         0
         0         0    3.0000
```


4.3

A =

```
149   -50  -154
537   180   546
-27     9   -25
```

>> [U,S,V]=svd(A)

U =

```
0.0228    0.9994    0.0247
-0.9988    0.0217    0.0434
0.0428   -0.0257    0.9988
```

S =

```
787.6038         0         0
         0 219.4293         0
         0         0 16.3725
```

V =

```
-0.6782    0.7349   -0.0004
-0.2292   -0.2110    0.9502
-0.6982   -0.6445   -0.3115
```

4.7

正定矩阵的特征值是正的，能对角化，有 n 个相互正交的特征向量。

4.12

$$A = U\Sigma V, A^T = V^T \Sigma^T U^T$$

$$\begin{pmatrix} 0 & A^T \\ A & 0 \end{pmatrix} X = \begin{pmatrix} 0 & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \lambda \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$$

$$A^T X_2 = \lambda X_1, AX_1 = \lambda X_2$$

$$\Rightarrow AA^T X_2 = \lambda AX_1, A^T AX_1 = \lambda A^T X_2$$

$$\Rightarrow AA^T X_2 = \lambda^2 X_2, A^T AX_1 = \lambda^2 X_1$$

$$\Rightarrow X_1 \leftarrow V, X_2 \leftarrow U \text{ (注: } \leftarrow \text{ 表示取 } U \text{ 和 } V \text{ 中的列向量)}$$

$$\therefore AA^T = U\Sigma V(U\Sigma V)^T = U\Sigma VV^T \Sigma^T U^T = U\Sigma \Sigma^T U^T$$

$$\therefore AA^T U = U\Sigma \Sigma^T U^T U = U\Sigma \Sigma^T \text{ (也就是奇异值分别乘上 } U \text{ 的各列)}$$

对于 $A^T A, V$ 也有相同讨论

6.4

解：满秩分解 $A^+ = G^H (F^H A G^H)^{-1} F^H$.

$$\begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} = \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} (1)$$

$$\begin{aligned} \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix}^+ &= (1) \left(\begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \begin{pmatrix} 1 \\ 5 \\ 7 \end{pmatrix} (1) \right)^{-1} \begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \\ &= \frac{1}{1^2 + 5^2 + 7^2} \begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \\ &= \frac{1}{75} \begin{pmatrix} 1 & 5 & 7 \end{pmatrix} \\ &= \begin{pmatrix} 0.133 & 0.0667 & 0.0933 \end{pmatrix} \end{aligned}$$

利用彭罗斯逆的性质 $A^\dagger = (A^H A)^\dagger A^H$ ，也可以。

Matlab:

```
>> pinv([1 5 7]')
```

ans =

```
0.0133    0.0667    0.0933
```

```
>> pinv([1 5 7]')*75
```

ans =

```
1.0000    5.0000    7.0000
```

6.5

按定义证明

$$(1) AA^T (A(A^T A)^{-2} A^T) AA^T = AA^T$$

$$(2) (A(A^T A)^{-2} A^T) AA^T (A(A^T A)^{-2} A^T) = A(A^T A)^{-2} A^T$$

$$(3) (AA^T (A(A^T A)^{-2} A^T))^T = (A(A^T A)^{-2} A^T)^T AA^T = A(A^T A)^{-2} A^T AA^T = A(A^T A)^{-1} A^T$$

$$AA^T (A(A^T A)^{-2} A^T) = A(A^T A)^{-1} A^T$$

(4)略

6.7

证明: $A = U\Sigma V, A^2 = U\Sigma^2 U^H = V\Sigma^2 V^H, A^{+2} = U^H \Sigma^{+2} U = V^H \Sigma^{+2} V$
 $M = V^H \Sigma^{+} U^H, M^2 = V^H \Sigma^{+2} V$

6.12

方程是相容的，有解，根据推论 1，和定理 1 的证明，可得证明步骤。

6.13

$$A\mathbf{x} + \varepsilon = \mathbf{b}$$

$$Q(\mathbf{x}) = (A\mathbf{x} - \mathbf{b})^T W (A\mathbf{x} - \mathbf{b})$$

$$\mathbf{d}Q(\mathbf{x}) = \text{tr}(\mathbf{d}(A\mathbf{x} - \mathbf{b})^T W (A\mathbf{x} - \mathbf{b}))$$

$$= \text{tr}(\mathbf{d}\mathbf{x}^T A^T W (A\mathbf{x} - \mathbf{b})) + \text{tr}((A\mathbf{x} - \mathbf{b})^T W A \mathbf{d}\mathbf{x})$$

$$= 2\text{tr}((A\mathbf{x} - \mathbf{b})^T W A \mathbf{d}\mathbf{x})$$

$$\Rightarrow \nabla_{\mathbf{x}} Q = ((A\mathbf{x} - \mathbf{b})^T W A)^T$$

$$\Rightarrow ((A\mathbf{x} - \mathbf{b})^T W A)^T = 0$$

$$\Rightarrow A^T W^T (A\mathbf{x} - \mathbf{b}) = \mathbf{0}$$

$$\Rightarrow A^T W^T A\mathbf{x} - A^T W^T \mathbf{b} = \mathbf{0}$$

$$\Rightarrow A^T W^T A\mathbf{x} = A^T W^T \mathbf{b}$$

$$\mathbf{x} = (A^T W^T A)^+ A^T W^T \mathbf{b} (\text{极小范数最小二乘解})$$

$$\|\varepsilon\|_2^2 = \varepsilon^T \varepsilon = \sqrt{\varepsilon^T \varepsilon \varepsilon^T \varepsilon}$$

$$\|\varepsilon\|_2^4 = \varepsilon^T \varepsilon \varepsilon^T \varepsilon (\text{极值属性一样})$$

$$\varepsilon^T \varepsilon \varepsilon^T \varepsilon = \varepsilon^T (\varepsilon \varepsilon^T - W + W) \varepsilon = \varepsilon^T (\varepsilon \varepsilon^T - W) \varepsilon + \varepsilon^T W \varepsilon$$

$$= (A\mathbf{x} - \mathbf{b})^T (\varepsilon \varepsilon^T - W) (A\mathbf{x} - \mathbf{b}) + Q(\mathbf{x})$$

当把 \mathbf{x} 看成已经求得的解时，

$$\mathbf{E}((A\mathbf{x} - \mathbf{b})^T (\varepsilon \varepsilon^T - W) (A\mathbf{x} - \mathbf{b}) + Q(\mathbf{x}))$$

$$= (A\mathbf{x} - \mathbf{b})^T (\mathbf{E} \varepsilon \varepsilon^T - W) (A\mathbf{x} - \mathbf{b}) + Q(\mathbf{x})$$

$$= (A\mathbf{x} - \mathbf{b})^T (R - W) (A\mathbf{x} - \mathbf{b}) + Q(\mathbf{x})$$

$$\text{当 } W = R \text{ 时, } \mathbf{E} \|\varepsilon\|_2^4 = \mathbf{E} \varepsilon^T W \varepsilon$$

7.9

$$\mathbf{d}f(\mathbf{x}) = \mathbf{d}tr(f(\mathbf{x})) = \mathbf{d}tr(a^T \mathbf{x}) = tr(a^T \mathbf{d}\mathbf{x})$$

$$\mathbf{d}^2 f(\mathbf{x}) = \mathbf{d}tr(a^T \mathbf{d}\mathbf{x}) = tr(a^T \mathbf{d}(\mathbf{d}\mathbf{x})) = 0 \Rightarrow H = 0$$

$$\mathbf{d}f(\mathbf{x}) = \mathbf{d}tr(f(\mathbf{x})) = \mathbf{d}tr(\mathbf{x}^T A\mathbf{x}) = tr(\mathbf{x}^T (A + A^T) \mathbf{d}\mathbf{x})$$

$$\mathbf{d}^2 f(\mathbf{x}) = \mathbf{d}tr(\mathbf{x}^T (A + A^T) \mathbf{d}\mathbf{x}) = tr(\mathbf{d}\mathbf{x}^T (A + A^T) \mathbf{d}\mathbf{x}) \Rightarrow H = A + A^T$$

7.12

$$\begin{aligned}\mathbf{d}tr(AX^{-1}B) &= \mathbf{d}tr(tr(AX^{-1}B)) = \mathbf{d}tr(AX^{-1}B) = tr(BA\mathbf{d}X^{-1}) \\ &= tr(-BAX^{-1}(\mathbf{d}X)X^{-1}) = tr(-X^{-1}BAX^{-1}(\mathbf{d}X)) \\ &\Rightarrow \nabla_X tr(AX^{-1}B) = -X^{-1}BAX^{-1} \\ \mathbf{d}tr(AX^T BXC) &= \mathbf{d}tr(CAX^T BX) = tr(CA\mathbf{d}X^T BX) + tr(CAX^T B\mathbf{d}X) \\ &= tr(BXC A\mathbf{d}X^T) + tr(CAX^T B\mathbf{d}X) \\ &= tr((BXCA)^T \mathbf{d}X) + tr(CAX^T B\mathbf{d}X) \\ &\Rightarrow \nabla_X tr(AX^T BXC) = (BXCA)^T + CAX^T B\end{aligned}$$